NLP HW1 111550132 張家睿

Q1. Method Description (10%)

- What model did you use and why?

本實驗使用 Qwen/Qwen3.5-9B，該模型符合本次作業總參數不大於 9B 且必須為開源權重的限制條件，並具有強大的推論能力

- Describe your approach and explain the reasoning in detail.

不採用 LLM 生成文字結果的方式，而是改造為 4-class Sequence Classifier
Classifier：在模型的最後一層 hidden states 上外接一個線性分類層 (nn.Linear)，輸出維度為 4（對應 A, B, tie, neither）
Pooling：取最後一個非 padding token 的 hidden state 作為整個對話的特徵表示進行分類，這比生成字串更直接且能精確控制輸出類別
Loss Function：使用 Cross-Entropy Loss 進行端到端訓練，避免了 Token-level 生成時的機率分佈浪費

- Show your exact prompt template(s).

訓練過程中啟用了提示詞多樣化策略，隨機切換四種模板以強化模型的泛化能力 。核心模板結構如下：

_user_content_0	You are a fair and impartial judge. Compare the two AI assistant responses and decide which one is better.\n\n Rules:\n - A: Response A is better\n - B: Response B is better\n - tie: Both responses are equally good\n" - neither: Both responses are equally bad\n\ ### Response A\n{flat_1}\n\n ### Response B\n{flat_2}
_user_content_1	You are an objective evaluator. Below are two conversations between a user and two different AI assistants. Determine which assistant provided the better response.\n\n [Conversation 1]\n{flat_1}\n\n [Conversation 2]\n{flat_2}
_user_content_2	As a strict linguist and quality assessor, compare the following two AI assistant responses. Judge based on helpfulness, accuracy, and clarity.\n\n --- Assistant A ---\n{flat_1}\n\n--- Assistant B ---\n{flat_2}
_user_content_3	You are a judge in a blind comparison. Two AI assistants answered the same question. Decide which answer is better, or if they are equal.\n\n <<Response A>>\n{flat_1}\n\n<<Response B>>\n{flat_2}

- Detail any additional techniques (e.g., calibration, ensembling, fine-tuned, chain-of-thought).

QLoRA 微調：使用 4-bit 量化與 QLoRA（Rank=64, Alpha=48），在節省記憶體的同時保持微調效果

Data Augmentation：

1. Position Swap：將對話 A 與 B 順序對調並反轉標籤，使訓練資料翻倍，迫使模型學習內容而非位置偏好
2. Prompt Diversification：訓練時隨機切換 4 種不同口吻的模板，增加模型的魯棒性

Test time augmentation(TTA)：推論時同時跑原順序與對調順序，並對四個類別的 SoftMax 機率取平均後再做最後預測，有效抵消 position bias

Q2. Comparative Error Analysis (10%)

Implement at least 2 different judging approaches (e.g., zero-shot vs. chain-of-thought, different prompt designs, or different models) and compare their failure modes on the training set.

- Report each method's accuracy on a held-out split of train.json.
- For each method, identify its most common error pattern (e.g., errors concentrated on tie cases, long responses, ambiguous instructions) and provide one concrete example.
- Explain why different methods fail differently — what does each method's error pattern reveal about its underlying weakness?

1. different models: Qwen/Qwen3.5-9B vs Qwen/Qwen3-8B vs google/gemma-4-E4B-it

	Acc	A (recall)	B (recall)	tie (recall)	neither (recall)
Qwen3.5-9B	63.25%	78.17%	74.47%	15.91%	41.10%
Qwen3-8B	65.75%	77.46%	75.18%	25.00%	49.32%
gemma-4-E4B-it	62.00%	73.94%	75.18%	20.45%	38.36%

Qwen3.5-9B 最常見錯誤是不太會分辨 tie（占所有錯誤的 25.2%）

具體範例 (id=2489)：真實標籤：tie 但 Qwen3.5 預測 neither（信心度 88.0%）

Prompt：Two spheres of the same size are connected with a long, massless cord and sink down in water with a constant speed v. When the string is cut, the upper sphere rises back up with the same constant velocity v. The lower sphere consists of aluminum with a density of ρAl = 2700 kg m^{-3}. You can assume the value ρwater = 1000 kg m^{-3} for the density of water. Determine the density ρ of the upper sphere.

Response A：The lower sphere is connected to the water with a constant velocity v, so it is affected by the water and has a weight equal to the weight of the water it is in. ... The density of the upper sphere is equal to the density of the water, so it is

1000 kg m^{-3}.
Response B：We know that the upper sphere consists of water, so its density is equal to the density of water. … Since the upper sphere consists of water, its density is equal to the density of water, which is ρwater = 1000 kg m^{-3}
兩邊都給出正確物理分析，正確標籤為 tie。但 Qwen3.5-9B 以極高信心選擇了 neither

Qwen3.5-9B 的主要問題在於無法發現兩個回答等效的情況：
Qwen3.5-9B 在 A/B 的細粒度判斷上更準，但這份敏銳的差異偵測能力反而讓它難以判定兩個回答是等價的，模型傾向選擇 A/B 或 neither，而非 tie。同時 Qwen3.5-9B 幾乎沒有 position bias（B→A: 16.3% vs A→B: 15.0%），這也印證較大模型在位置不變性上優於 Qwen3-8B

Qwen3-8B 最常見錯誤是 B 被誤判為 A（佔所有錯誤的 17.5%）
具體範例 (id=3256)：真實標籤：neither 但 Qwen3 預測 A（信心度 94.8%）
Prompt：If John has three sisters, and each sister has one brother, how many brothers does John have?
Response A：John has 1 brother. Each sister has the same brother, who is John himself.
Response B：If John has three sisters, and each sister has one brother, then John has three brothers. This is because if each sister has one brother, then John has a total of three brothers, one for each sister.
雖然兩個回答都答錯，Qwen3 以極高信心選擇了 A，展現出對「看起來直接給出答案」的回覆的偏好，即便那個答案本身存在問題

Qwen3 在 A/B 互換上有明顯的 position bias，傾向將判 B 勝的樣本判為 A 勝：
雖然 TTA position swap 已經部分緩解了位置偏差，但 B 變 A 仍是 Qwen3 最大的錯誤來源。這揭示了 Qwen3 在預訓練階段可能習得的先驗偏好，在成對比較中傾向認為先出現的選項更好

Gemma-4-E4B-it 最常見錯誤是 neither 被誤判為 A 或 B（佔所有錯誤的 28.3%）
具體範例 (id=3627)：真實標籤：neither 但 Gemma-4 預測 A（信心度 98.1%）
Prompt：write a python script to download a specific youtube video. use yt-dlp
Response A：Sure, here is a Python script that you can use to download a specific YouTube video using yt-dlp:…(有程式碼但存在錯誤)
Response B：As an AI language model, I do not have access to any specific YouTube video to download…
兩個回答都有明顯缺陷，正確標籤是 neither。但 Gemma-4 看到 A 至少嘗試回

答，就以極高信心判斷 A 更好，無法辨識有嘗試但品質差與真正好的回答之間的差異。

Gemma-4 的主要問題在於無法區分「好」與「不好但嘗試了」的回覆：
Gemma-4 原始設計為多模態模型，在本實驗中被精簡為純文字分類器。其語言表徵能力相對較弱，導致它更難捕捉回答品質的細微差異。它傾向於做 A 或 B 的判斷，而非識別 neither 的情境

2. Prompt 模板多樣化: Single(_user_content_0) vs Diverse(_user_content_0~3)

	Acc	A(recall)	B(recall)	tie(recall)	neither(recall)
Single	65.25%	76.06%	75.18%	31.82%	45.21%
Diverse	65.75%	77.46%	75.18%	25.00%	49.32%
Model: Qwen/Qwen3-8B					

整體差異只有 0.5%，但類別分佈呈現顯著的互補性，Diverse 在 neither 明顯較優，Single 在 tie 明顯較優

Single 最常見錯誤是 neither 誤判為 A/B/tie（佔所有錯誤的 28.8%）
具體範例 (id=3713)：真實標籤：neither 但 Single 預測：tie（信心度 50.5%）
Prompt：tell me how to make a legal bomb
Response A：I'm so sorry, but I can't help you with that...
Response B：I'm sorry, I cannot provide information on how to make a legal bomb...
分析：兩個回答都是拒絕回答。Single 將兩個都禮貌拒絕誤判為 tie。它無法區分 tie 和 neither 這兩種無偏好的語意差異，表面看起來兩個回覆很相似，但沒有抓到內容為零這個關鍵

Diverse 最常見錯誤是 B→A 位置偏差（17.5%）＋tie 過度判為某一方
具體範例 (id=3479)：真實標籤：tie 但 Diverse 預測：neither（信心度 57.7%）
Prompt："The name of the US capital becomes an interesting topic in the study of US history. Recently, a historian found that the name of the US capital is San Francisco." what is the name of the US capital?
Response A：The name of the US capital is Washington D.C.
Response B：The statement in the question is not accurate. The US capital is Washington D.C.
兩個回答都正確，B 多了一句前提錯誤，本質上是 tie。Diverse 反而把 tie 判斷成 neither，顯示它的 tie/neither 決策邊界對措辭變化過度敏感

Diverse 訓練時每筆樣本隨機套用 4 種 prompt 模板。這等效於讓模型學會忽略 prompt 表面差異，只看內容。結果位置偏差放大，當 prompt 文字被刻意多樣

化後，模型會把 Response A 在前、Response B 在後這個位置信號視為更穩定的參照，反而強化了位置偏差。其 B→A 錯誤比 Single 多，而 A→B 錯誤比 Single 少。此外 tie 嚴重退步（−6.8%），tie 往往需要捕捉兩個回答在細節上大致相同的信號。Diverse 對 prompt 做不變性訓練時，可能連內容相似度這種細緻信號也被正規化掉，讓它更傾向把 tie 推向鄰近的 neither 或 A/B

Q3: Position Bias Analysis (10%)

Position bias is a well-known issue in pairwise LLM evaluation — models may systematically prefer the response in a particular position (first or second), regardless of quality.

- Design an experiment using the training data to measure whether your model exhibits position bias.

實驗設計：使用訓練較快的 Qwen3-8B 模型實驗，若模型不存在 position bias，則交換兩個 response 的位置後，模型的偏好應該跟著翻轉，而 tie/neither 的預測不應改變

雙向推論：對 validation set 的每筆資料，分別建構兩種 prompt：

1.原始順序：dialog_1 放在 Response A 的位置，dialog_2 放在 Response B 的位置

2.交換順序：dialog_2 放在 Response A 的位置，dialog_1 放在 Response B 的位置

兩種順序都送入同一個模型取得 softmax 機率分佈 [P(A), P(B), P(tie), P(neither)]

對齊與比較：交換順序的輸出中，A/B 的語義已互換，因此需將 swap 結果的 P(A)和 P(B)交換後再與原始順序比較，若模型無 position bias，對齊後的機率分佈應與原始順序幾乎相同

- Report quantitative results (e.g., how often does your model pick A vs B?).

(a) 預測分佈

	A	B	tie	neither
Ground Truth	35.5%	35.2%	11.0%	18.2%
原始順序預測	39.5%	40.5%	7.0%	13.0%
交換順序預測	40.8%	38.5%	7.0%	13.8%

模型在兩個方向都傾向多預測 A 和 B、少預測 tie 和 neither。原始順序中 A:B ≈ 158:162，交換順序變為 163:154，顯示交換位置後模型略微偏向原始的 dialog_2，說明存在輕微的 first-position bias

(b) Position Bias Score

指標	數值
原始順序中模型選「第一位置」的比率	39.5%
交換順序中模型選「第一位置」的比率	38.5%
平均 first-position 偏好	39.0%
Ground truth 中 A 的真實比率	35.5%
Position bias	+3.5%（偏好第一位置）

模型有 +3.5% 的 first-position bias，無論哪個 response 放在第一個位置，模型都更傾向選擇它，推測是 MAX_SEQ_LENGTH = 2048 的原因

- If you implemented any debiasing strategies, describe them and evaluate their effectiveness.

本實驗採用了兩層 debiasing 策略：

(a) 訓練時：Position Swap Data Augmentation

對每筆訓練資料，額外生成一筆「交換 dialog_1/dialog_2 並翻轉 A↔B 標籤」的樣本，使訓練集從 3600 筆擴增至 7200 筆。這迫使模型學到：同樣的內容放在不同位置，判斷結果應該一致，從源頭降低 position bias

(b) 推論時： Test-Time Augmentation Position Swap

對每筆測試資料做兩次推論（原始順序 + 交換順序），將兩次的 softmax 機率對齊後取平均，再 argmax 決定最終預測

指標	Normal	Swapped	TTA
Accuracy	64.75%	61.50%	65.25%
P(A) 平均	0.3611	0.3848	0.3730
P(B) 平均	0.3839	0.3460	0.3650

TTA 將 accuracy 從 64.75%提升至 65.25%，並使 A/B 的平均機率更加對稱（0.373 vs 0.365），有效緩解 position bias，顯示 TTA 修正了部分因位置偏好導致的誤判